UNIVERSIDAD DISTRITAL FJDC

Facultad de Ingeniería

Tarea T4: Distribuciones de Probabilidad

Modelado y Validación con Python

Asignatura: Probabilidad y Estadística

Docente: Alberto Acosta Lopez

Estudiante: Daniel Alejandro Castro Becerra

Código: 20242020271

Índice

1. Distribuciones Discretas **2**

1.1. Distribución Binomial (Bernoulli) 2

1.2. Distribución de Poisson 5

2. Distribuciones Continuas **8**

2.1. Distribución Normal 8

3. Resumen de Resultados **10**

4. Conclusiones **10**

1. Distribuciones Discretas

1.1. Distribución Binomial (Bernoulli)

La distribución Binomial generaliza el experimento de Bernoulli a n ensayos independientes, cada uno con probabilidad de éxito p. Su función de masa de probabilidad (PMF) es:

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \ldots, n \tag{1}$$

Sus parámetros principales son:

- **Media:** $\mu = np$
- **Varianza:** $\sigma^2 = np(1-p)$

Enunciado

Se lanza un dado no alterado 5 veces. El evento de éxito es obtener el número 3. Dado que el dado es justo, la probabilidad de éxito en cada lanzamiento es:

$$p = \frac{1}{6} \approx 0{,}1667, \qquad n = 5$$

Se pide calcular:

I. $P(X = 2)$: que el 3 aparezca exactamente 2 veces.

II. $P(X \leq 1)$: que el 3 aparezca como máximo 1 vez.

III. $P(X \geq 2)$: que el 3 aparezca al menos 2 veces.

Desarrollo

i. Exactamente 2 veces — $P(X = 2)$

$$\begin{aligned} P(X = 2) &= \binom{5}{2} \left(\frac{1}{6}\right)^2 \left(\frac{5}{6}\right)^3 && (2) \\ &= 10 \times 0{,}02778 \times 0{,}57870 && (3) \\ &\approx \boxed{0{,}1608} && (4) \end{aligned}$$

ii. Máximo 1 vez — $P(X \leq 1)$

$$P(X \leq 1) = P(X = 0) + P(X = 1) \tag{5}$$

$$P(X = 0) = \binom{5}{0} \left(\frac{1}{6}\right)^0 \left(\frac{5}{6}\right)^5 = \left(\frac{5}{6}\right)^5 \approx 0{,}4019 \tag{6}$$

$$P(X = 1) = \binom{5}{1} \left(\frac{1}{6}\right)^1 \left(\frac{5}{6}\right)^4 = 5 \times 0{,}1667 \times 0{,}4823 \approx 0{,}4019 \tag{7}$$

$$P(X \leq 1) = 0{,}4019 + 0{,}4019 \approx \boxed{0{,}8038} \tag{8}$$

iii. Al menos 2 veces — $P(X \geq 2)$

Se usa el complemento para simplificar el cálculo:

$$P(X \geq 2) = 1 - P(X \leq 1) \tag{9}$$

$$= 1 - 0{,}8038 \tag{10}$$

$$\approx \boxed{0{,}1962} \tag{11}$$

Código de Validación

```
import scipy.stats as stats
import matplotlib.pyplot as plt
import numpy as np

n, p = 5, 1/6

# Validacion de los tres casos
print(f"i.  P(X=2)   = {stats.binom.pmf(2, n, p):.4f}")   #
   0.1608
print(f"ii. P(X<=1)  = {stats.binom.cdf(1, n, p):.4f}")   #
   0.8038
print(f"iii.P(X>=2)  = {1 - stats.binom.cdf(1, n, p):.4f}") #
   0.1962

# Grafica de la distribucion
x = range(n + 1)
y = [stats.binom.pmf(i, n, p) for i in x]

colores = ['tomato' if i >= 2 else 'skyblue' for i in x]

plt.figure(figsize=(7, 4))
```

```
plt.bar(x, y, color=colores, edgecolor='black')
plt.title('Binomial: Lanzamiento de dado (n=5, p=1/6)')
plt.xlabel('Numero de veces que aparece el 3')
plt.ylabel('Probabilidad')
plt.xticks(list(x))
plt.axhline(0, color='black', linewidth=0.8)
from matplotlib.patches import Patch
leyenda = [Patch(color='tomato', label='X >= 2 (al menos 2)'),
           Patch(color='skyblue', label='X < 2')]
plt.legend(handles=leyenda)
plt.tight_layout()
plt.show()
```

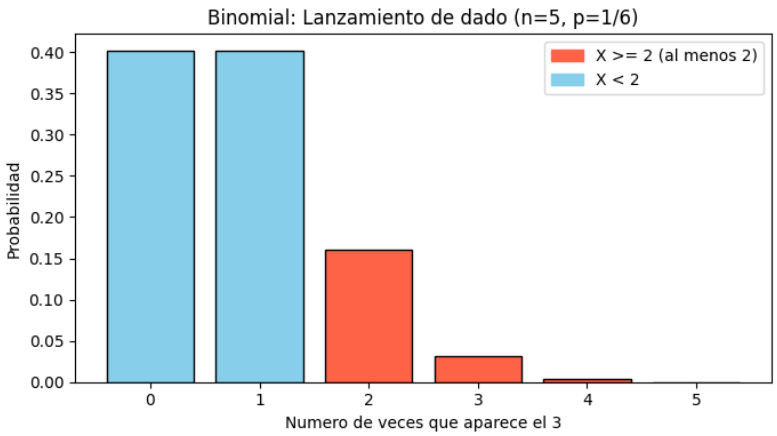

Figura 1: Distribución Binomial para $n = 5$ lanzamientos de un dado con $p = 1/6$. Las barras rojas representan el evento $X \geq 2$.

1.2. Distribución de Poisson

La distribución de Poisson modela el número de eventos que ocurren en un intervalo fijo cuando la tasa promedio λ es constante. Su PMF es:

$$P(X = k) = \frac{e^{-\lambda}\lambda^k}{k!}, \quad k = 0, 1, 2, \ldots \tag{12}$$

Sus parámetros son:

- **Media:** $\mu = \lambda$
- **Varianza:** $\sigma^2 = \lambda$

Enunciado

La probabilidad de que un automóvil sufra un accidente es $p = 0{,}001$. Entre las 4pm y 6pm, aproximadamente 1000 autos pasan por una intersección. ¿Cuál es la probabilidad de que ocurran **2 o más accidentes**?

Justificación del modelo

Dado que $n = 1000$ es grande y $p = 0{,}001$ es pequeño, se cumplen las condiciones para aproximar la Binomial con una Poisson, donde:

$$\lambda = n \cdot p = 1000 \times 0{,}001 = 1$$

Desarrollo

Se pide $P(X \geq 2)$. Usando el complemento:

$$P(X \geq 2) = 1 - P(X \leq 1) = 1 - \big[P(X = 0) + P(X = 1)\big] \tag{13}$$

Calculando $P(X = 0)$:

$$P(X = 0) = \frac{e^{-1} \cdot 1^0}{0!} = e^{-1} \approx 0{,}3679 \tag{14}$$

Calculando $P(X = 1)$:

$$P(X = 1) = \frac{e^{-1} \cdot 1^1}{1!} = e^{-1} \approx 0{,}3679 \tag{15}$$

Resultado final:

$$P(X \geq 2) = 1 - (0{,}3679 + 0{,}3679) \tag{16}$$
$$= 1 - 0{,}7358 \tag{17}$$
$$\approx \boxed{0{,}2642} \tag{18}$$

Existe aproximadamente un **26.42 %** de probabilidad de que ocurran 2 o más accidentes en esa intersección durante el intervalo de tiempo analizado.

Código de Validación

```
import scipy.stats as stats
import matplotlib.pyplot as plt
import numpy as np

lam = 1  # lambda = n * p = 1000 * 0.001

# Validacion
p0 = stats.poisson.pmf(0, lam)
p1 = stats.poisson.pmf(1, lam)
p_geq2 = 1 - stats.poisson.cdf(1, lam)

print(f"P(X=0)   = {p0:.4f}")    # 0.3679
print(f"P(X=1)   = {p1:.4f}")    # 0.3679
print(f"P(X>=2)  = {p_geq2:.4f}") # 0.2642

# Grafica
x = range(8)
y = [stats.poisson.pmf(i, lam) for i in x]
colores = ['tomato' if i >= 2 else 'skyblue' for i in x]

plt.figure(figsize=(7, 4))
plt.bar(x, y, color=colores, edgecolor='black')
plt.title(f'Poisson: Accidentes en interseccion ($\\lambda$=1)')
plt.xlabel('Numero de accidentes')
plt.ylabel('Probabilidad')
plt.xticks(list(x))
from matplotlib.patches import Patch
leyenda = [Patch(color='tomato', label='X >= 2'),
           Patch(color='skyblue', label='X < 2')]
plt.legend(handles=leyenda)
```

```
plt.tight_layout()
plt.show()
```

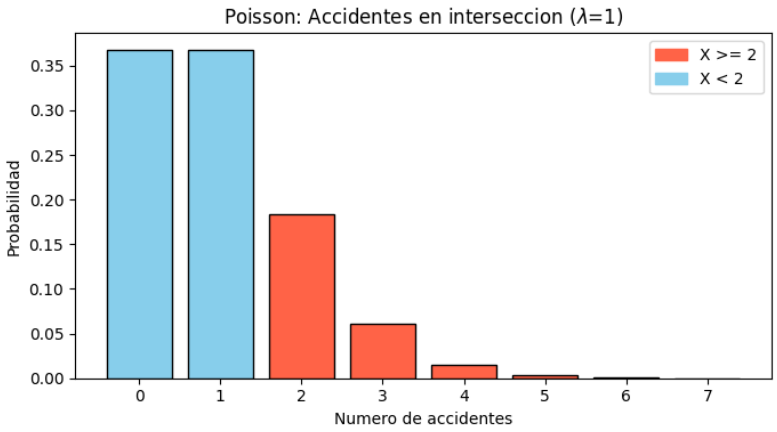

Figura 2: Distribución de Poisson con $\lambda = 1$. Las barras rojas representan el evento de 2 o más accidentes ($P \approx 0{,}2642$).

2. Distribuciones Continuas

2.1. Distribución Normal

La distribución Normal es la más importante en estadística. Su función de densidad de probabilidad (PDF) es:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}}\, e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad x \in \mathbb{R} \tag{19}$$

Para calcular probabilidades se estandariza mediante:

$$Z = \frac{X-\mu}{\sigma} \sim N(0,1) \tag{20}$$

Enunciado

Dada una distribución normal estándar $Z \sim N(0,1)$, calcule el área bajo la curva:

a) A la derecha de $z = 1{,}84$.

b) Entre $z = -1{,}97$ y $z = 0{,}86$.

Desarrollo

a) Área a la derecha de $z = 1{,}84$

El área a la derecha corresponde a $P(Z > 1{,}84)$. Usando la tabla de la distribución normal estándar:

$$\begin{aligned} P(Z > 1{,}84) &= 1 - P(Z \leq 1{,}84) && (21)\\ &= 1 - \Phi(1{,}84) && (22)\\ &= 1 - 0{,}9671 && (23)\\ &\approx \boxed{0{,}0329} && (24) \end{aligned}$$

Esto significa que solo el **3.29 %** de los valores de una distribución normal estándar superan $z = 1{,}84$.

b) Área entre $z = -1{,}97$ **y** $z = 0{,}86$

El área entre dos valores se obtiene como la diferencia de acumuladas:

$$\begin{aligned} P(-1{,}97 < Z < 0{,}86) &= \Phi(0{,}86) - \Phi(-1{,}97) && (25)\\ &= 0{,}8051 - 0{,}0244 && (26)\\ &\approx \boxed{0{,}7807} && (27) \end{aligned}$$

El **78.07 %** del área bajo la curva normal estándar se encuentra entre $z = -1{,}97$ y $z = 0{,}86$.

Código de Validación

```
import numpy as np
import scipy.stats as stats
import matplotlib.pyplot as plt

# Validacion de los dos casos
p_a = 1 - stats.norm.cdf(1.84)
p_b = stats.norm.cdf(0.86) - stats.norm.cdf(-1.97)

print(f"a) P(Z > 1.84)              = {p_a:.4f}")  # 0.0329
print(f"b) P(-1.97 < Z < 0.86)     = {p_b:.4f}")  # 0.7807

# --- Grafica a) ---
x = np.linspace(-4, 4, 400)
y = stats.norm.pdf(x)

fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(12, 4))

# Subplot a
ax1.plot(x, y, color='black', lw=2)
ax1.fill_between(x, y, where=(x >= 1.84), color='steelblue',
   alpha=0.5,
                 label=f'P(Z>1.84) = {p_a:.4f}')
ax1.axvline(1.84, color='steelblue', linestyle='--')
ax1.set_title('a)  rea  a la derecha de z = 1.84')
ax1.set_xlabel('z')
ax1.set_ylabel('Densidad')
ax1.legend()

# Subplot b
ax2.plot(x, y, color='black', lw=2)
ax2.fill_between(x, y, where=((x >= -1.97) & (x <= 0.86)),
                 color='darkorange', alpha=0.5,
                 label=f'P(-1.97<Z<0.86) = {p_b:.4f}')
ax2.axvline(-1.97, color='darkorange', linestyle='--')
ax2.axvline(0.86, color='darkorange', linestyle='--')
ax2.set_title('b)  rea  entre z = -1.97 y z = 0.86')
ax2.set_xlabel('z')
```

```
ax2.set_ylabel('Densidad')
ax2.legend()

plt.tight_layout()
plt.show()
```

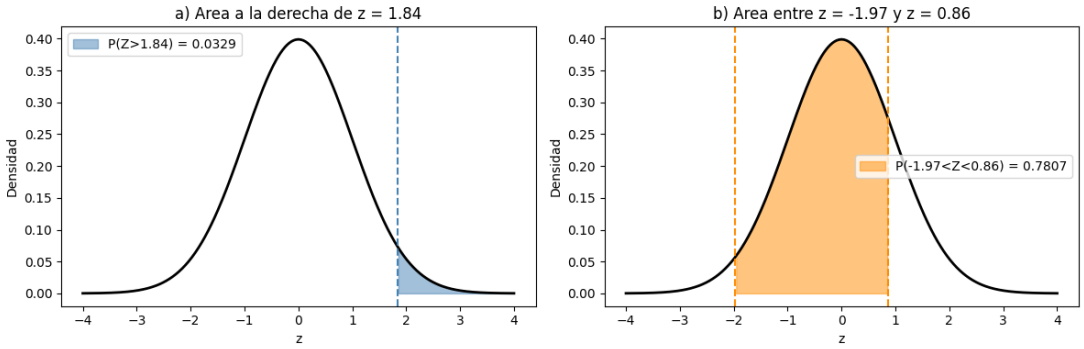

Figura 3: Distribución Normal estándar: *(a)* área a la derecha de $z = 1{,}84$ ($P \approx 0{,}0329$); *(b)* área entre $z = -1{,}97$ y $z = 0{,}86$ ($P \approx 0{,}7807$).

3. Resumen de Resultados

Distribución	**Caso**	**Expresión**	**Resultado**
Binomial $(n = 5, p = 1/6)$	i	$P(X = 2)$	0,1608
Binomial $(n = 5, p = 1/6)$	ii	$P(X \leq 1)$	0,8038
Binomial $(n = 5, p = 1/6)$	iii	$P(X \geq 2)$	0,1962
Poisson $(\lambda = 1)$		$P(X \geq 2)$	0,2642
Normal estándar	a	$P(Z > 1{,}84)$	0,0329
Normal estándar	b	$P(-1{,}97 < Z < 0{,}86)$	0,7807

Cuadro 1: Resumen de todos los resultados obtenidos en la tarea T4.

4. Conclusiones

1. **Distribución Binomial:** permite modelar experimentos con resultados dicotómicos en n ensayos independientes. En el ejercicio del dado, el complemento resultó ser una herramienta clave para calcular $P(X \geq 2)$ de manera eficiente, evitando sumar múltiples términos individualmente.

2. **Distribución de Poisson:** cuando n es grande y p es pequeño, la Binomial puede aproximarse con Poisson usando $\lambda = np$. En el ejercicio de accidentes, esta apro-

ximación simplificó considerablemente el cálculo, obteniendo que hay un 26.42 % de probabilidad de que ocurran 2 o más accidentes en la intersección durante el intervalo estudiado.

3. **Distribución Normal:** el uso de la estandarización a Z permite calcular cualquier probabilidad con la tabla de la distribución normal estándar. Para áreas a la derecha se aplica el complemento de la acumulada, y para áreas entre dos valores se calcula la diferencia de acumuladas, como se verificó en los dos casos del ejemplo 6.2.

4. **Python como herramienta de validación:** el uso de `scipy.stats` permitió verificar con precisión todos los resultados obtenidos manualmente, mientras que `matplotlib` facilitó la visualización de las áreas de probabilidad, reforzando la interpretación geométrica de cada distribución.